## 2026년도 머신러닝 모델 개발 프로젝트

# AI개발 수행내역서

| | |
|---|---|
| **과제명** | 머신러닝 기반 가스 센서 데이터 변화 감지 및 가스 분류 성능 관리 시스템 |
| **담당자** | 김수현 |

**2026년 10월 29일**

# 목 차

**AI개발 수행내용** ····· **3**
**1. 추진 배경 및 목적** ····· **3**
**2. 프로젝트 목표** ····· **4**
2.1 과제 범위 ····· 4
2.2 과제 추진 방법 ····· 4
**연구개발 주요 결과물** ····· **7**
**1. 데이터 수집** ····· **7**
**2. 데이터 분석** ····· **7**
2.1 탐색적 데이터 분석 EDA ····· 7
2.2 데이터 전처리 ····· 11
**3. 모델 학습 및 성능 분석** ····· **12**
3.1 전처리 및 Pipeline 구성 ····· 12
3.2 분류 모델 비교 및 공식 기준 모델 선정 ····· 12
3.3 공식 기준 모델의 성능 저하 및 오분류 분석 ····· 14
3.4 분류 성능 개선 실험 ····· 16
3.5 특징 영향 및 중요도 분석 ····· 18
3.6 데이터 분포 변화 감지 ····· 19
3.7 연구 결과 종합 ····· 21
**4. 프로토타이핑(화면)** ····· **22**
4.1 웹앱 개요 ····· 22
4.2 주요 분석 기능 ····· 22
4.3 모델 재학습 및 관리 ····· 23
**5. 결론 및 향후 과제** ····· **25**
5.1 결론 ····· 25
5.2 주요 트러블슈팅 ····· 25
5.3 한계점 및 향후 과제 ····· 25
5.4 프로젝트 회고 ····· 26
**부록** ····· **27**
부록 A 주요 모델 학습 조건 ····· 27
부록 B 단계별 개선 실험 비교 ····· 27
부록 C 정답 기반 적응 세부 결과 ····· 28
**참고문헌** ····· **29**

## AI개발 수행내용

### 1. 추진 배경 및 목적

○ 추진 배경

산업 현장에서 가스 센서는 특정 가스의 존재 여부와 종류를 식별하기 위해 활용됨. 특히 제조 공정 및 가스 측정 환경에서는 정확한 가스 식별이 중요하며, 센서의 측정 특성이 일정하게 유지되어야 신뢰할 수 있는 분석 결과를 얻을 수 있음.

그러나 가스 센서는 사용 시간의 경과, 주변 환경 변화, 센서의 특성 변화 등에 따라 동일한 가스를 측정하더라도 출력 신호의 패턴이 달라질 수 있음. 이러한 현상을 센서 드리프트(Sensor Drift)라고 하며, 과거 데이터로 학습한 가스 분류 모델의 성능이 새로운 측정 환경에서 저하되는 원인이 될 수 있음.

일반적인 랜덤 분할 평가에서는 학습 데이터와 평가 데이터에 여러 측정 시기의 샘플이 섞일 수 있어 실제 새로운 시기의 성능을 충분히 검증하기 어려움. 또한 전체 정확도가 높더라도 특정 가스에서 심각한 오분류가 발생할 수 있으며, 실제 측정 환경에서는 정답 데이터가 없어 분류 성능을 즉시 확인하기 어려운 경우도 있음.

이에 본 프로젝트에서는 UCI Gas Sensor Array Drift Dataset을 활용하여 측정 시기에 따른 데이터 분포 변화와 가스 분류 성능의 관계를 분석하고, 분포 변화 감지 및 모델 재학습 기능을 통해 분류 모델의 지속적인 성능 관리를 지원하고자 함.

○ 산업 활용 가능성

본 시스템은 가스 센서의 분류 성능과 측정 데이터의 변화를 분석하여 센서의 신뢰성 평가 및 유지관리를 지원할 수 있음. 주요 활용 분야는 다음과 같음.

**표 1 활용 사례별 시스템 역할과 검증 상태**

| 활용 분야 | 활용 방안 |
|---|---|
| **가스 센서 연구 및 성능 평가** | 기준 가스를 반복 측정하여 가스별 분류 성능과 오분류 경향 분석 |
| **장기간 사용 센서의 유지관리** | 측정 시기에 따른 데이터 분포와 분류 성능 변화를 분석하여 추가 점검 및 재보정 필요성 판단 지원 |
| **측정 패턴 변화 감지** | 기존 측정 데이터와 새로운 데이터의 분포 차이를 감지하여 센서 상태 및 측정 조건 점검 지원 |
| **제조 공정의 가스 식별 보조** | 공정에서 예상한 가스와 예측 결과를 비교하여 이상 여부에 대한 추가 확인 지원 |

○ 목적

가스 종류를 단순히 분류하는 것을 넘어, 센서 측정 특성 변화에 따른 분류 성능 저하를 분석하고 데이터 분포 변화를 감지하여 가스 분류 결과의 신뢰성을 판단하는 데 필요한 정보를 제공함.

머신러닝 기반 가스 분류 및 분포 변화 감지 모델을 결합한 시스템을 구축함. 또한 신규 정답 데이터를 활용한 모델 재학습, 성능 비교, 승인·전환·롤백 기능을 통해 가스 분류 모델의 지속적인 성능 관리와 유지보수를 지원함.

## 2. 프로젝트 목표

○ UCI Gas Sensor Array Drift Dataset의 128개 센서 특징을 활용하여 6종 가스를 분류하는 머신러닝 모델을 구축하고, 랜덤 분할과 시간순 평가를 통해 모델별 성능을 비교하여 최적의 분류 모델을 선정함.

○ Batch별·가스별 분류 성능과 오분류 특성을 분석하고, 다양한 전처리 및 모델 개선 실험을 수행하여 측정 시기에 따른 분류 성능 저하와 개선 가능성을 검증함.

○ RFF-MMD² 기반 데이터 분포 변화 감지 기능을 구현하고, 가스 분류 결과와 성능 분석 정보를 시각적으로 확인할 수 있는 Streamlit 기반 웹앱을 구축함.

○ 신규 정답 데이터 등록 및 검증, 후보 모델 재학습과 성능 비교, 수동 승인, 운영 모델 전환 및 롤백 기능을 구현하여 지속적인 모델 관리가 가능한 시스템을 구축함.

## 2.1 과제 범위

**표 2 과제 범위별 수행 내용**

| 과제구분 | | 내용 |
|---|---|---|
| **데이터셋** | 데이터 수집 | UCI Gas Sensor Array Drift Dataset의 10개 Batch, 13,910개 샘플과 128개 센서 특징을 활용함. |
| | EDA | 가스별·Batch별 데이터 분포, 주요 특징의 통계량과 상관관계를 분석하여 측정 시기에 따른 특성 변화를 확인함. |
| | 데이터 전처리 | 결측치·중복값·이상값을 점검하고, 데이터 누수를 방지하기 위해 학습 데이터 기준으로 결측치 처리와 표준화를 수행함. |
| **머신러닝** | 모델 학습 | Logistic Regression, Random Forest, SVM 등의 분류 모델을 학습하고 성능을 비교함. |
| | 모델 성능 평가 | Accuracy, Precision, Recall, Macro F1과 Confusion Matrix를 활용하여 랜덤 분할 및 시간순 평가 결과를 비교함. |
| | 모델 개선 및 선정 | 학습 범위 확장, 특징 선택, 가중치 및 모델 설정 변경 등 다양한 개선 실험을 수행하고 최종 SVM 모델을 선정함. |
| **분포 변화 분석** | 오분류 및 성능 저하 분석 | Batch별·가스별 성능 변화와 특정 가스의 오분류를 분석하여 모델의 한계를 파악함. |
| | 분포 변화 감지 | RFF-MMD² 기반으로 새로운 측정 데이터와 기준 데이터의 분포 차이를 계산하고 변화 여부를 감지함. |
| **프로토타이핑** | 웹앱 구현 | Streamlit을 활용하여 CSV 업로드, 가스 분류, 분포 변화 감지, 성능 평가 및 결과 다운로드 기능을 구현함. |
| | 재학습 데이터 관리 | 신규 정답 데이터의 유효성을 검증하고 학습·검증 데이터로 분리하여 저장하는 기능을 구현함. |
| | 후보 모델 재학습 | 기존 학습 데이터와 신규 데이터를 결합하여 후보 SVM을 학습하고 기존 모델과 성능을 비교함. |
| | 모델 승인 및 복구 | 후보 모델의 수동 승인, 운영 모델 전환, 버전 이력 관리 및 이전 모델로의 롤백 기능을 구현함. |

## 2.2 과제 추진 방법

### 2.2.1 구축 대상 선정 기준

○ 데이터의 신뢰성과 가용성

- UCI Machine Learning Repository에서 공개한 Gas Sensor Array Drift Dataset을 활용함. 실제 가스 센서 측정 데이터를 기반으로 하며, 데이터 출처와 구성이 명확해 연구에 적합함.

- 총 13,910개 측정 샘플과 128개 센서 특징, 6종 가스 및 10개 Batch로 구성되어 있어 데이터 분석과 머신러닝 모델 학습에 활용할 수 있음.

○ 가스 분류 및 시기별 성능 분석의 적합성

- 가스 종류가 명확하게 구분된 다중 분류 데이터로, 다양한 머신러닝 알고리즘을 적용하고 가스별 분류 성능을 비교할 수 있음.

- 10개 Batch로 구분된 데이터 구조를 활용하여 과거 측정 데이터로 학습한 모델이 이후 시기의 데이터에서도 분류 성능을 유지하는지 평가할 수 있음.

○ 산업 활용 및 시스템 확장 가능성

- 가스 분류 결과와 측정 데이터의 분포 변화를 함께 분석하여 센서의 성능 평가 및 유지관리를 지원하는 시스템을 구축할 수 있음.

- 향후 동일한 128개 특징 구조를 갖춘 신규 센서 데이터를 등록하고, 모델 재학습 및 성능 비교를 수행할 수 있도록 확장할 수 있음.

### 2.2.2 AI 예측 분석 모델 적용 대상

**표 3 AI 예측 분석 모델 적용 대상**

| 대상기능 | 수집 데이터 | 예측모델인자 (독립변수) | AI예측 분석 대상 |
|---|---|---|---|
| 가스 분류 및 센서 데이터 변화 분석 | UCI Gas Sensor Array Drift Dataset의 6종 가스 측정 데이터, 10개 Batch, 128개 센서 특징 | 센서 16개에서 추출한 128개 수치형 특징(f001~f128) | 6종 가스 종류 예측, 시기별 분류 성능 비교, 가스별 오분류 분석 |
| 분포 변화 감지 | 기준 센서 데이터 및 신규 센서 측정 데이터 | 128개 센서 특징의 분포와 기준 데이터 간 차이 | RFF-MMD² 기반 분포 변화 점수 산출 및 변화 여부 감지 |
| 모델 재학습 및 성능 관리 | 기존 학습 데이터, 신규 정답 데이터 및 모델 평가 결과 | 128개 센서 특징, 실제 가스 정답(학습·평가용) | 후보 모델 재학습, 기존 모델과 성능 비교, 수동 승인 및 모델 전환·롤백 |

### 2.2.3 AI 분석 모델 구축 프로세스

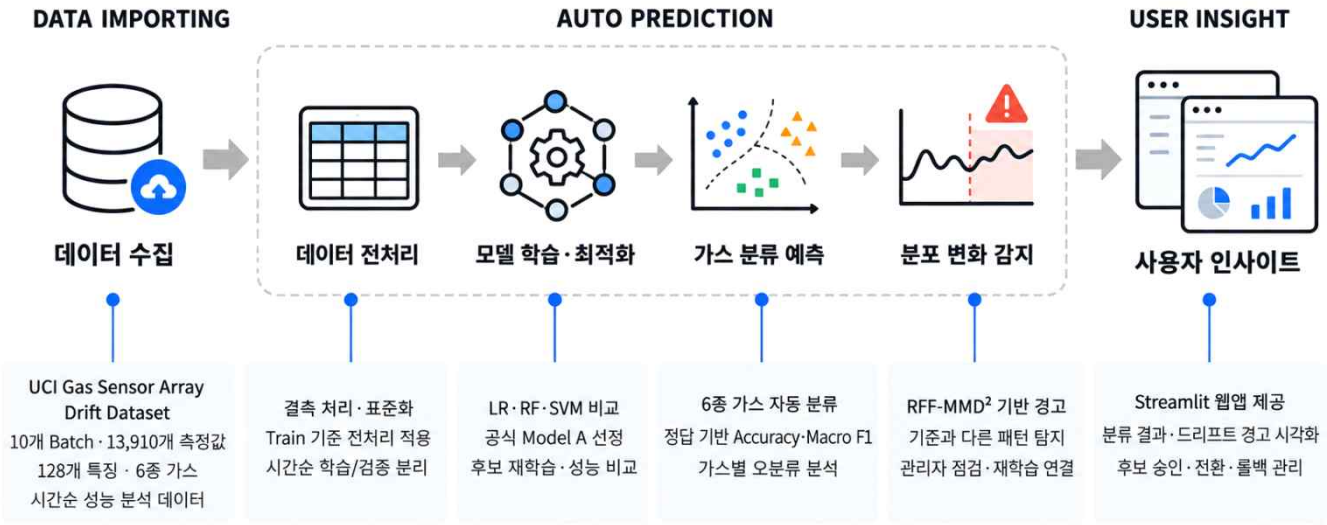



그림 1 AI 분석 모델 구축 프로세스

## 연구개발 주요 결과물

# 1. 데이터 수집

○ 데이터 출처

- UCI Machine Learning Repository, Gas Sensor Array Drift Dataset (ID 224)

- 원 데이터: Vergara (2012), https://doi.org/10.24432/C5RP6W

○ 종속 변수

**표 4 종속 변수 구성**

| 구분 | 주요 컬럼 | 수집 내용 |
|---|---|---|
| 예측 대상 | gas | 가스 6종 구분: 에탄올, 에틸렌, 암모니아, 아세트알데하이드, 아세톤, 톨루엔 |

○ 독립 변수

**표 5 독립 변수(센서 특징) 구성**

| 구분 | 주요 컬럼 | 수집 내용 |
|---|---|---|
| 정적 반응 | 센서별 ΔR | 가스 노출에 따른 센서 저항 변화 |
| 정규화 반응 | 센서별 normalized_R | 센서 반응 크기를 정규화한 값 |
| 상승 구간 반응 | 센서별 EMA rise | 센서 반응 상승 과정의 특징 3개 |
| 하강 구간 반응 | 센서별 EMA decay | 센서 반응 하강 과정의 특징 3개 |

※ 센서 16개에서 각각 8개씩 추출한 총 128개 특징(f001~f128)으로 구성.

# 2. 데이터 분석

## 2.1 탐색적 데이터 분석 EDA

### 2.1.1 가스 종류별 분포

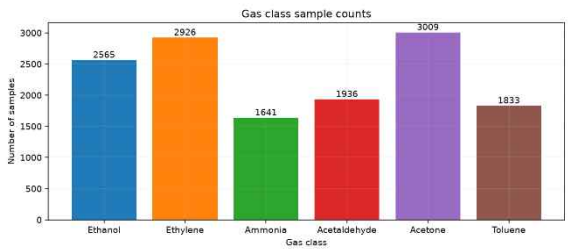



그림 2 가스 종류별 표본 수

○ 전체 13,910개 샘플 중 Acetone이 3,009개(21.6%)로 가장 많고, Ammonia가 1,641개(11.8%)로 가장 적게 나타남.

○ 최대·최소 클래스의 표본 수 차이는 약 1.83배로, 가스별 표본 수 차이를 고려하여 성능을 평가할 필요가 있음.

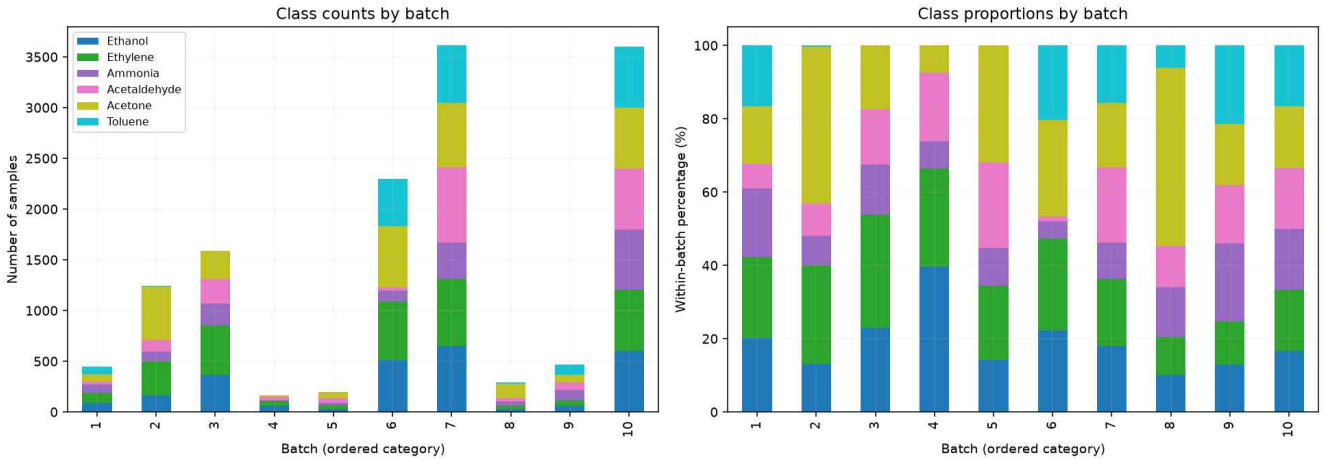



그림 3 Batch별 표본 수 및 가스 구성

○ Batch별 표본 수는 161개(Batch 4)부터 3,613개(Batch 7)까지 차이가 있으며, 가스 구성 비율도 일정하지 않음.

○ Batch 3~5에는 Toluene이 없고, Batch 2와 Batch 8에는 각각 5개와 18개만 포함되어 있어 전체 분포와 함께 시기별 구성을 확인할 필요가 있음.

○ Batch는 측정 시기를 구분하는 단위이며, 각 Batch 사이를 동일한 시간 간격으로 해석하지 않음.

### 2.1.2 제거 컬럼

**표 6 분석에서 제외한 컬럼과 제외 사유**

| 구분 | 제외 컬럼 | 제외 사유 |
|---|---|---|
| 목표 변수 | gas | 가스 종류를 나타내는 정답으로 분리하여 예측 입력에서 제외 |
| 출처 정보 | Batch, source_line, row_id | 측정 시기와 원본 행을 식별하는 정보로, 센서 반응 대신 식별 정보를 학습하는 것을 방지 |
| 신규 등록 정보 | session_id, measured_at | 신규 데이터의 세션 구분과 시각 추적에 사용하며 모델 입력에서 제외 |

○ 가스 분류에는 센서 특징 f001~f128만 사용하고, 정답과 출처·등록 정보는 별도로 관리함.

### 2.1.3 가스 종류별 센서 반응 비교

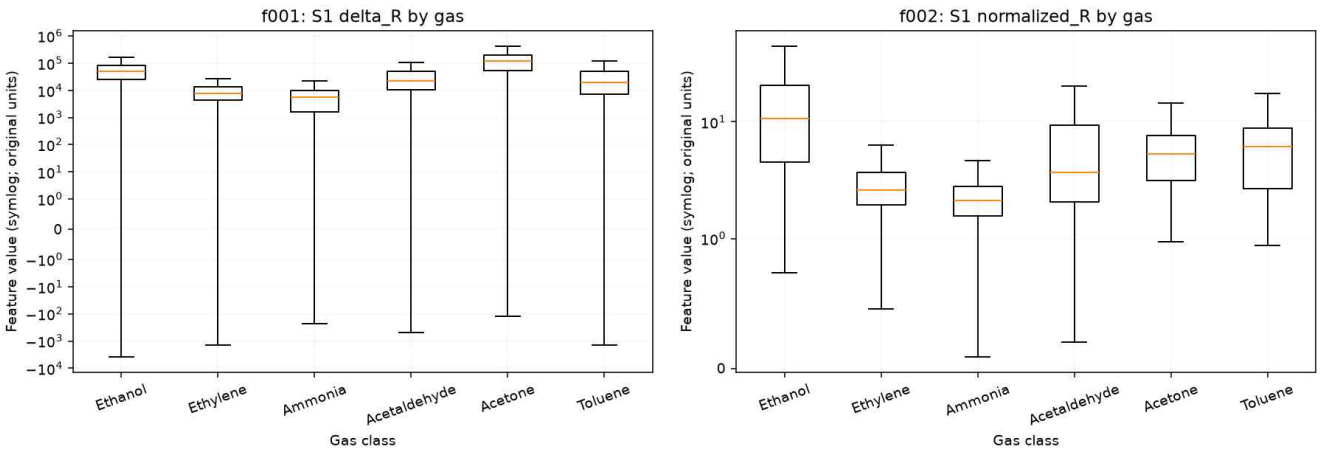



그림 4 센서 S1의 저항 변화(f001) 및 정규화 반응(f002)

○ 가스별 센서 반응의 중앙값과 분포에 차이가 나타남. 정규화 반응(f002)에서는 Ethanol의 중앙값이 높고 Ethylene과 Ammonia는 낮게 나타남.

○ 가스별 분포가 서로 겹치므로 하나의 특징만으로 구분하기 어렵고, 여러 센서 특징의 조합을 활용할 필요가 있음.

### 2.1.4 동일 가스의 Batch별 특징 분포 변화

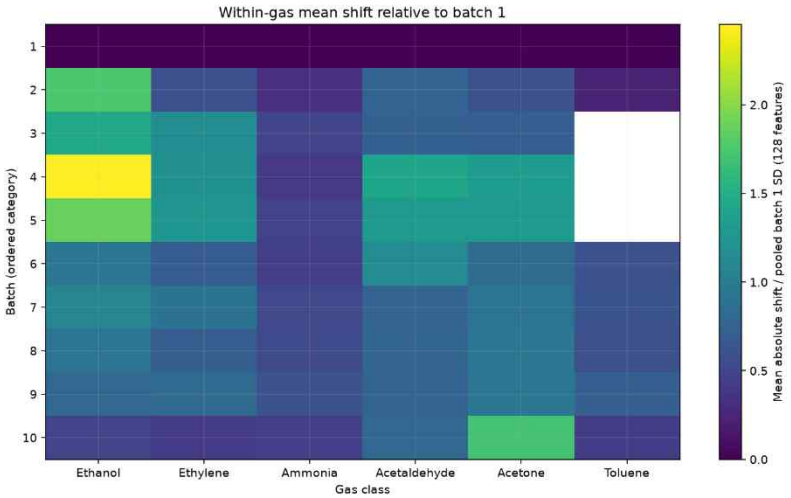



그림 5 동일 가스의 Batch 1 대비 평균 특징 이동

○ 동일한 가스에서도 Batch에 따라 특징 분포가 달라짐. Batch 10의 Acetone은 Batch 1 대비 평균 특징 이동이 1.718로, 6종 가스 중 가장 크게 나타남.

○ 측정 시기에 따른 변화를 고려하기 위해 과거 Batch로 학습하고 이후 Batch에서 평가하는 시간순 평가가 필요함. 농도·환경 정보가 없어 변화 원인을 센서 드리프트만으로 단정하지 않음.

※ 평균 특징 이동은 Batch 1 전체 표준편차로 표준화한 특징 차이의 평균이며, 빈칸은 해당 가스의 표본이 없음을 의미함.

### 2.1.5 센서 특징 간 상관관계 히트맵

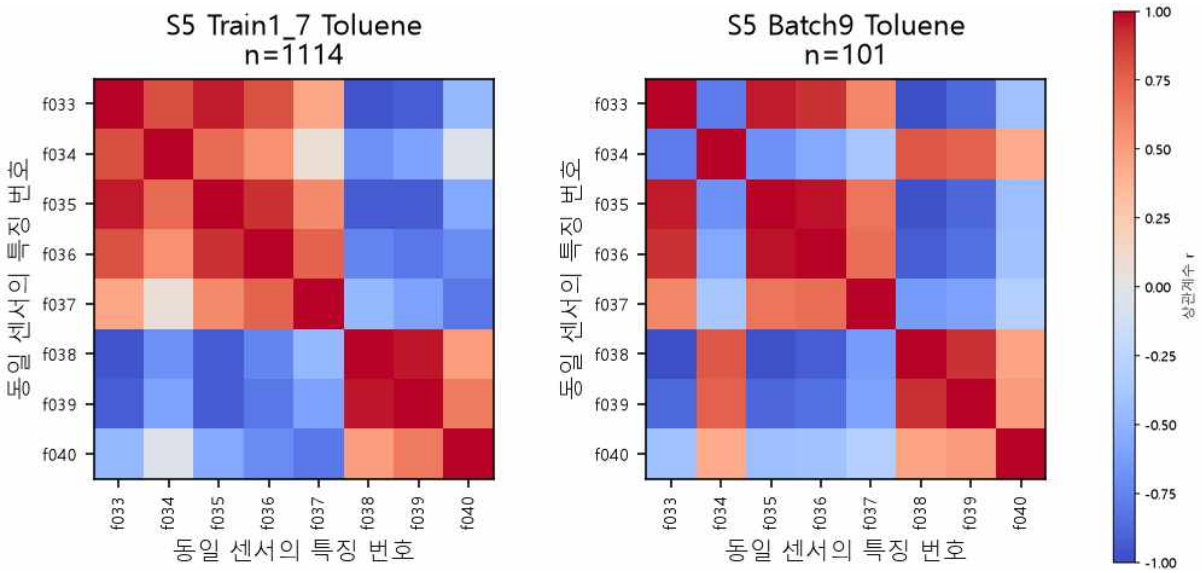



그림 6 센서 S5의 특징 간 Pearson 상관관계 비교

○ Toluene의 센서 S5 특징을 비교한 결과, f033과 f034의 상관계수가 Train 1~7에서 0.815, Batch 9에서 -0.786으로 나타나 관계의 방향이 바뀜.

○ 같은 가스에서도 시기에 따라 일부 센서 특징 간 관계가 달라질 수 있음을 확인함. 전체 128개 특징의 상관행렬이 아니라 센서 S5의 8개 특징을 비교한 결과임.

※ 모델 학습 이후 수행한 사후 진단 결과로, 이 상관관계를 이용해 모델 입력 특징을 다시 선정하지 않음.

### 2.1.6 수치형 변수 기초통계 및 이상치 후보 확인

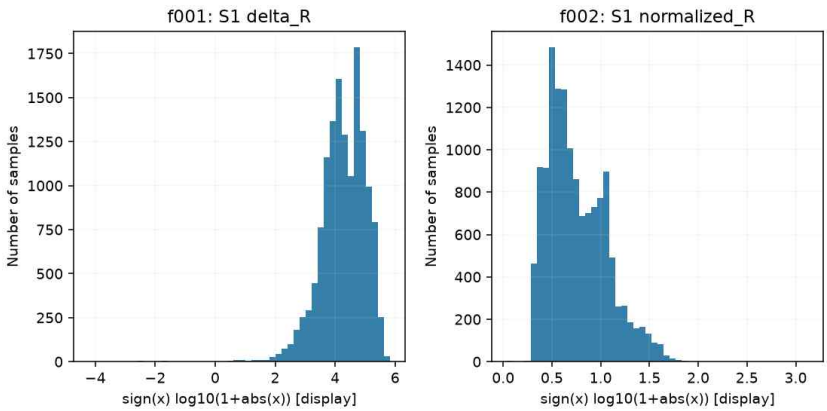



그림 7 센서 S1의 저항 변화 및 정규화 반응 분포

○ f001의 평균은 50,435.07, 표준편차는 69,844.79이며, 최솟값 -16,757.60부터 최댓값 670,687.35까지 넓게 분포함.

○ f001의 1.5×IQR 기준 이상치 후보는 1,418개(10.19%)임. 실제 센서 반응일 수 있으므로 자동 삭제하지 않고, 특징별 규모 차이는 표준화로 보완함.

※ 그림 7의 가로축은 분포를 보기 위해 부호를 보존한 로그 형태로 표시했으며, 원본 특징값을 변경한 것은 아님.

## 2.2 데이터 전처리

### 2.2.1 결측치 및 이상치 처리

**표 7 결측치·이상치 점검 및 처리 내용**

| 구분 | 대상 변수 | 처리 내용 | 처리 결과 및 목적 |
|---|---|---|---|
| 결측치 확인 | f001~f128 | 원본 결측치 0개 확인 | 결측치로 인한 삭제 없음 |
| 무한대 확인 | f001~f128 | 무한대 값 0개 확인 | 수치 유효성 확인 |
| 중복·정답 확인 | 센서 특징, gas | 정확 중복과 정답 충돌 0건 | 중복으로 인한 삭제 없음 |
| 이상치 후보 검토 | f001~f128 | IQR 후보를 일괄 삭제하지 않음 | 가스별 센서 반응 보존 |
| 결측치 대치 구성 | 일부 결측 입력 | 학습 데이터의 중앙값으로 대치 | 원본에는 적용 대상 없음;<br>신규 입력의 부분 결측에 대비 |
| 수치형 표준화 | LR·SVM 입력 | 학습 데이터의 평균과<br>표준편차로 변환 | 특징 간 규모 차이 완화 및<br>평가 정보 유입 방지 |
| 학습 변수 선정 | f001~f128 | 정답·메타데이터 제외,<br>128개 센서 특징 유지 | 센서 반응을 모델 입력으로 구성 |
| 클래스 불균형 대응 | gas | 공식 SVM에<br>class_weight=balanced 적용 | 학습 데이터의 클래스 빈도에<br>따라 오류 비용 조정 |

### 2.2.2 전처리 결과

**표 8 전처리 전후 데이터 구성**

| 항목 | 전처리 전 | 전처리 후 |
|---|---|---|
| 데이터 건수 | 13,910건 | 13,910건 유지 |
| 데이터 구성 | 가스 정답 1개 + 센서 특징 128개 | 정답·메타데이터와 입력 특징 분리 |
| 모델 입력변수 | 센서 특징 128개 | f001~f128의 128개 유지 |
| 목표 변수 | gas (1~6) | gas (1~6) |
| 범주형 입력변수 | 없음 | 없음 |
| 수치형 입력변수 | 128개 | 128개 |

### 2.2.3 전처리 결과 분석

○ 결측치·무한대·정확 중복·정답 충돌이 확인되지 않아 해당 사유로 삭제한 행은 없으며, 전체 13,910건을 유지함.

○ 128개 센서 특징은 모두 수치형이므로 범주형 인코딩 없이 사용함. 이상치 후보는 센서 반응일 가능성을 고려해 보존함.

○ 결측치 대치와 표준화는 학습 데이터에서만 기준을 계산하고, 검증·평가 데이터에는 같은 기준을 적용하도록 전처리와 모델을 Pipeline으로 연결함.

## 3. 모델 학습 및 성능 분석

3장은 ① 모델을 어떤 기준으로 평가하고 선정했는지(3.1~3.2), ② 선정한 모델이 이후 시기의 데이터에서 어떻게 성능이 떨어졌는지(3.3), ③ 이를 개선하기 위해 어떤 실험을 했고 무엇을 확인했는지(3.4~3.5), ④ 정답이 없는 상황에서 데이터 변화를 어떻게 감지하는지(3.6)의 순서로 정리함.

### 3.1 전처리 및 Pipeline 구성

**표 9 모델별 전처리·Pipeline 및 학습 설정**

| 모델 | 처리 흐름 | 주요 설정 | 적용 목적 |
|---|---|---|---|
| **Logistic Regression** | 특징 128개 → 중앙값 대치 → 표준화 → 분류 | C=1, solver=lbfgs, max_iter=10,000 | 선형 분류 기준모델 |
| **Random Forest** | 특징 128개 → 중앙값 대치 → 분류 | n_estimators=100, max_depth=None | 비선형 관계·특징 상호작용 학습 |
| **SVM (Model A)** | 특징 128개 → SimpleImputer(median) → StandardScaler → SVC | kernel=rbf, C=1, gamma=scale, class_weight=balanced, probability=False, random_state=42 | 비선형 가스 분류, 학습 클래스 빈도 보정 |

○ f001~f128만 입력하고 gas·Batch·행 식별 정보는 분리함. 대치·표준화 기준은 Train에서만 계산하고 같은 Pipeline으로 검증·평가에 적용하여 데이터 누수 방지.

○ 원본 결측치는 0개이나 신규 입력의 일부 결측에 대비해 Train 중앙값 대치 단계 유지. 이상치 후보는 센서 반응일 가능성을 고려해 보존함.

### 3.2 분류 모델 비교 및 공식 기준 모델 선정

#### 3.2.1 랜덤 분할과 시간순 평가 비교

**표 10 랜덤 분할과 시간순 분할의 모델별 Test 성능**

| 모델 | 랜덤 분할 Accuracy | 랜덤 분할 Macro F1 | Train 1 → 3~10 Accuracy | Train 1 → 3~10 Macro F1 | Train 1~3 → 5~10 Accuracy | Train 1~3 → 5~10 Macro F1 |
|---|---|---|---|---|---|---|
| Logistic Regression | 0.9921 | 0.9919 | 0.4424 | 0.3138 | 0.6197 | 0.5493 |
| Random Forest | 0.9946 | 0.9947 | 0.4354 | 0.3274 | 0.5093 | 0.4595 |
| SVM (RBF) | 0.9849 | 0.9845 | 0.3757 | 0.2929 | 0.6040 | 0.5788 |

※ 랜덤 분할은 가스 비율 유지 Train 60% / Validation 20% / Test 20%(Test 2,782건), Macro Precision·Recall은 LR 0.9920/0.9918, RF 0.9952/0.9941, SVM 0.9861/0.9832. 시간순 평가 건수는 12,221건(Train 1)과 10,474건(Train 1~3)임.

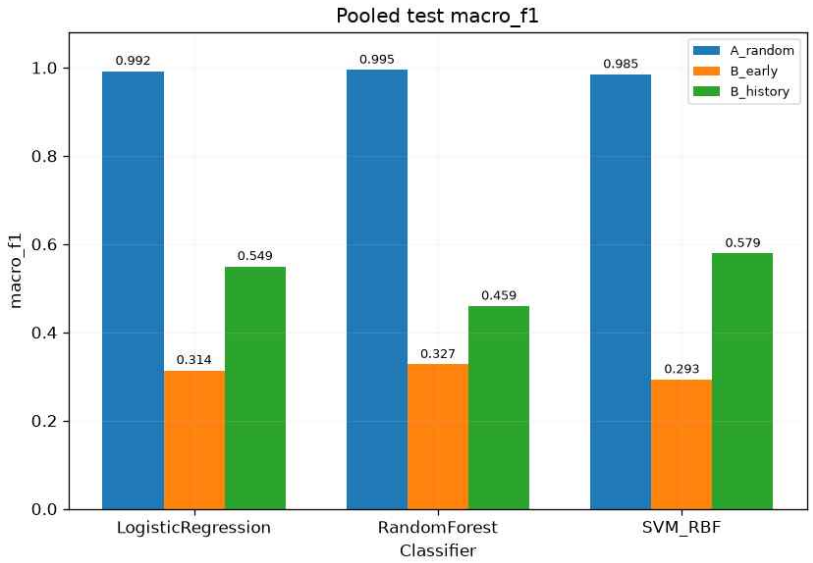



그림 8 랜덤 분할과 시간순 분할의 Macro F1 비교

○ 랜덤 분할에서는 세 모델 모두 Macro F1 0.98 이상이나, 과거 Batch로 학습해 이후 Batch를 평가하면 0.29~0.58로 급락함. 랜덤 분할 최고 모델(Random Forest)과 시간순 최고 모델(SVM)도 다름.

○ 랜덤 분할은 같은 Batch의 다른 표본을 이미 학습하므로 이후 시기 성능을 대변하지 못함. 실제 사용 조건과 같은 시간순 평가를 주 평가로 채택함.

※ 세 실험은 학습량·수집 시기·가스 구성·평가 표본이 모두 다름. 점수 차이를 센서 드리프트만의 효과로 해석하지 않음.

### 3.2.2 공식 기준 모델 Model A 선정

○ Batch 1~6의 5,933건으로 학습하고 Batch 7~8의 3,907건을 Validation으로 고정함. 선정 기준은 두 Validation Batch의 Macro F1 동일 가중 평균임.

**표 11 Validation(Batch 7~8)의 계열별 대표 후보 비교**

| 대표 후보 | Batch 평균 Macro F1 | 합산 Macro F1 | Toluene Recall | Acetaldehyde Recall |
|---|---|---|---|---|
| Logistic Regression | 0.8062 | 0.8469 | 0.9710 | 0.3874 |
| Random Forest | 0.6517 | 0.7261 | 0.6877 | 0.1776 |
| **SVM balanced (Model A)** | **0.8970** | 0.8971 | 0.8908 | 0.6293 |

○ SVM balanced가 Batch 평균 Macro F1 0.8970으로 가장 높고 Acetaldehyde Recall도 0.6293으로 가장 높아 공식 기준 모델로 선정함(이하 'SVM 모델(Model A)'). 기본 가중치 대비 balanced 적용으로 Validation 0.8629 → 0.8970 확인.

※ 후보와 모델 지문은 Batch 9~10 평가 전에 고정함. Batch 9~10은 모델을 고른 뒤 성능을 확인한 사후 평가 자료이며, 개발 중 여러 번 확인했으므로 처음 보는 독립 Test가 아님. 공식 모델은 서비스 기준 모델을 의미하며 이후 시기 성능을 보장하는 인증 모델이 아님.

## 3.3 공식 기준 모델의 성능 저하 및 오분류 분석

### 3.3.1 Batch별 성능 변화

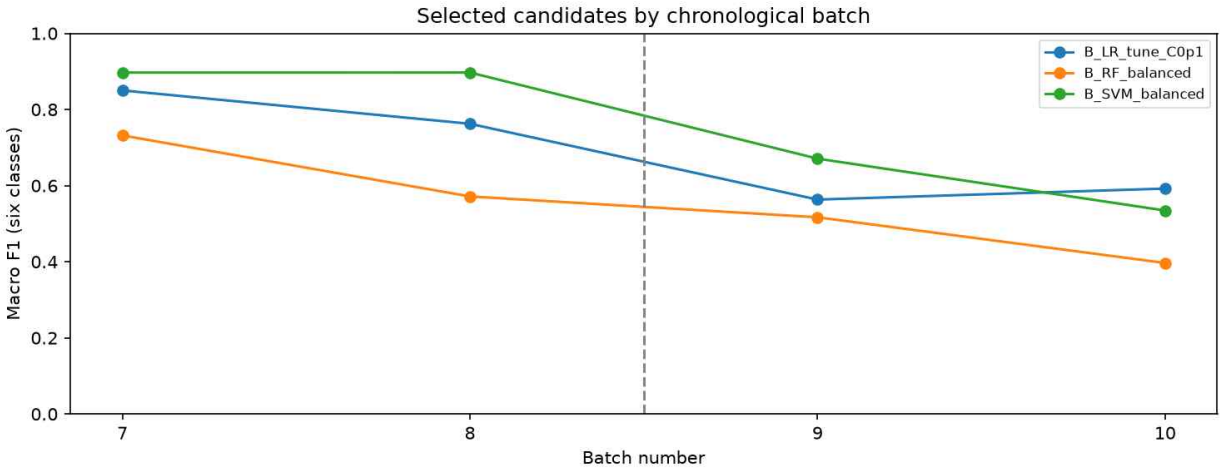



그림 9 계열별 대표 후보의 Batch별 Macro F1 변화

※ 범례의 B_LR_time_C0p1·B_RF_balanced·B_SVM_balanced는 각각 Logistic Regression(C=0.1)·Random Forest(balanced)·SVM(balanced) 계열의 대표 후보이며, SVM(balanced)이 SVM 모델(Model A)임. 점선은 Validation(7~8)과 사후 평가(9~10)의 경계.

**표 12 SVM 모델(Model A)의 Batch별 분류 성능**

| Batch | 평가 지위 | 표본 수 | Accuracy | Macro F1 |
|---|---|---|---|---|
| 7 | Validation | 3,613 | 0.8948 | 0.8969 |
| 8 | Validation | 294 | 0.9218 | 0.8971 |
| 9 | 사후 평가 | 470 | 0.7021 | 0.6708 |
| 10 | 사후 평가 | 3,600 | 0.5531 | 0.5346 |
| 9~10 합산 | 사후 평가 | 4,070 | 0.5703 | 0.5587 |

○ Batch 7·8의 Macro F1은 약 0.897이나 Batch 9는 0.6708, Batch 10은 0.5346으로 저하됨. 두 Batch의 동일 가중 평균은 0.6027로 합산 지표(0.5587)와 구분함. 학습 시기에서 벗어난 측정 자료에 대한 일반화 한계 확인.

### 3.3.2 가스별 오분류 분석

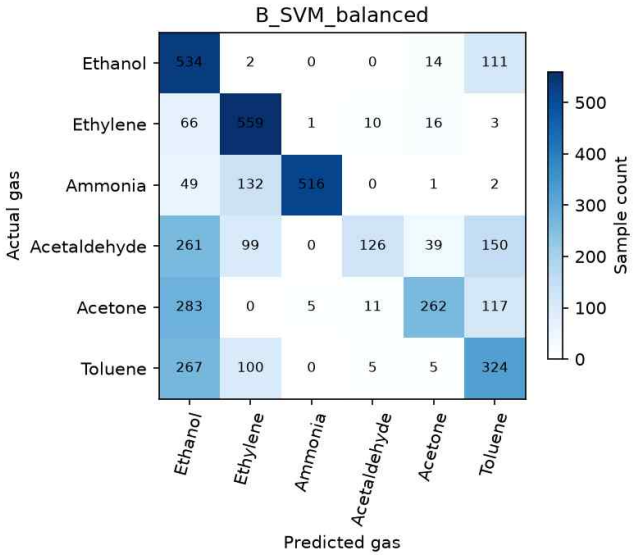



그림 10 SVM 모델(Model A)의 Batch 9~10 합산 Confusion Matrix

**표 13 주요 가스별 오분류와 실제 표본 수**

| 평가 구간 | 실제 가스 | 표본 수 | SVM 모델 정분류 | 주요 오분류 |
|---|---|---|---|---|
| Batch 9 | Toluene | 101 | 0건 (0.0%) | Ethanol 101건 |
| Batch 9 | Acetaldehyde | 75 | 42건 (56.0%) | Acetone 33건 |
| Batch 10 | Acetaldehyde | 600 | 84건 (14.0%) | Ethanol 261건 |
| Batch 10 | Acetone | 600 | 190건 (31.67%) | Ethanol 282건 |
| Batch S10 | Toluene | 600 | 324건 (54.0%) | Ethanol 166건 |

○ Batch 9 Toluene 101건 전부 Ethanol로 오분류되고, Batch 10 Acetaldehyde는 Recall 14.0%에 그침. 전체 평균 지표에서 가려지는 특정 가스의 실패 확인.

○ Train 1~6의 Toluene 546건 중 467건(85.53%)이 Batch 6에 집중되고 Batch 3~5에는 Toluene이 없음. Batch 9 Toluene은 같은 가스보다 다른 가스의 Train 표본에 더 가깝게 위치하고 센서 S5 특징 간 상관 구조 변화도 관찰됨. 학습 시기 대표성과 특징 공간 중첩을 개선 실험의 대상으로 설정함.

※ 특징 공간 중첩은 화학적 유사성이나 센서 고장의 증거가 아님. 농도·환경·장비 정보 부족으로 물리적 원인 확정 불가.

### 3.3.3 ROC Curve 및 AUC 평가

○ SVM 모델(Model A)의 Batch 9~10 합산 4,070건에 대해 SVM 클래스별 결정점수 기반 One-vs-Rest ROC 계산. 각 가스와 나머지 5종의 순위 구분 능력 평가.

**표 14 가스별 OvR AUC와 실제 분류 Recall**

| 가스 | 양성 표본 수 | 음성 표본 수 | OvR AUC | 실제 Recall |
|---|---|---|---|---|
| Ethanol | 661 | 3,409 | 0.8830 | 0.8079 |
| Ethylene | 655 | 3,415 | 0.9194 | 0.8534 |
| Ammonia | 700 | 3,370 | 0.9291 | 0.7371 |
| Acetaldehyde | 675 | 3,395 | 0.6376 | 0.1867 |
| Acetone | 678 | 3,392 | 0.9101 | 0.3864 |
| Toluene | 701 | 3,369 | 0.8238 | 0.4622 |
| Macro 평균 | - | - | 0.8505 | 0.5723 |

○ 6종 AUC 산술평균 0.8505, Acetaldehyde AUC 0.6376으로 최저 확인. Acetone은 AUC 0.9101이나 Recall 0.3864로, 점수 순위와 실제 분류 성능의 차이 확인.

※ 반복 확인한 사후 평가 결과임. 클래스 순서 1~6과 유한한 4,070×6 결정점수를 확인하고 독립적인 순위합 계산과 일치를 확인한 결과임. 점수 최댓값과 predict가 다른 48건은 기존 predict로 Recall을 계산함. 20-B 합성 기능 검증과 분포 변화 감지기의 결과와 구분함.

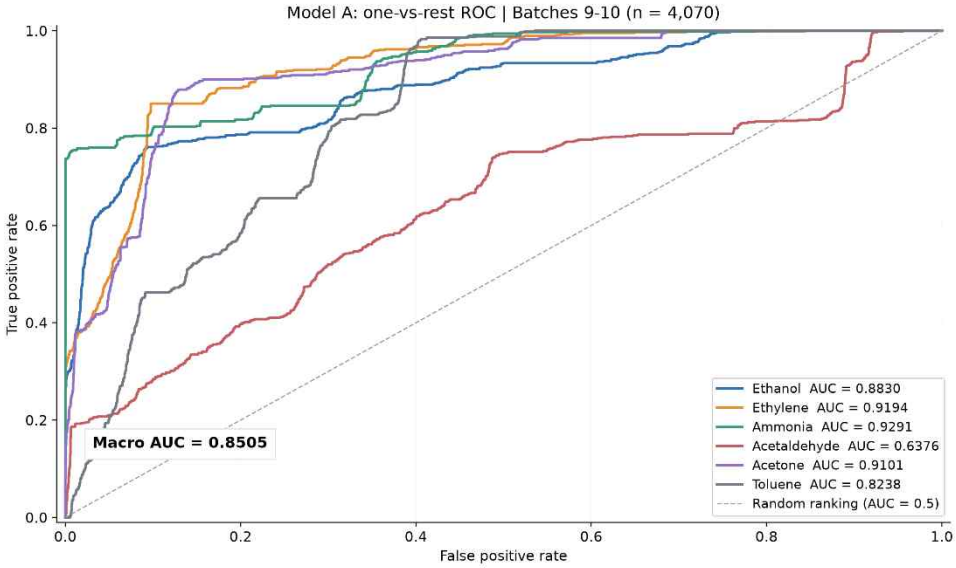



그림 11 SVM 모델(Model A)의 가스별 OvR ROC 및 AUC(Batch 9~10, 4,070건)

## 3.4 분류 성능 개선 실험

○ SVM 모델(Model A)의 시간순 성능 저하와 집중 오분류 원인 후보별로 대안을 검토함. 후보 탐색 결과와 공식 모델 교체를 분리하며, 성능이 낮아진 실험도 최종 판단의 근거로 함께 기록함.

○ 실험은 성능 저하의 원인을 네 방향에서 확인함. ① 학습 데이터에 어느 시기를 포함하는지, ② 입력 특징의 변환·선택과 학습 가중치, ③ 다른 알고리즘이나 여러 모델의 결합, ④ 새 시기의 정답 일부를 학습에 추가하는 방식. 표의 결론 열은 각 실험이 공식 모델 유지·교체 판단에 어떻게 반영되었는지를 나타냄.

**표 15 개선 실험 유형별 핵심 결과**

| 실험 유형 | 주요 변경 사항 | 핵심 결과 | 결론 |
|---|---|---|---|
| **학습 데이터 범위·구성** | Train 1~6 → 1~7 확장(Model B), 동일 843건의 학습 시기 구성 비교 | 9~10 Batch 평균 Macro F1 0.6027 → 0.7005. Batch 8은 0.8971 → 0.8744, Batch 9 Toluene 1/101. 843건 초기형 34.63%·분산형 60.90%·최근형 65.36% | 학습 시기 대표성이 성능에 큰 영향. 일부 가스 악화와 독립 검증 부재로 SVM 모델 유지 |
| **전처리·특징 선택·가중치** | balanced 가중치, C·gamma 조정, 저분산 13개 제거, 특징 선택, signed_log·Yeo-Johnson 변환, 시기 가중치 | balanced 0.8629 → 0.8970(채택). C=10 0.8699, gamma=0.001 0.7908. 저분산 제거 +0.37%p, signed_log +0.32%p, Yeo-Johnson 78.36%, time_recent +0.36%p(Toluene 평균 Recall 하락) | balanced만 SVM 모델에 반영. 나머지는 개선폭이 작거나 Fold별 불일치로 미적용 |
| **알고리즘·앙상블** | 특징 선택·이종 모델 결합, 시기별 SVM 결합(hard_equal), HistGradientBoosting | 과거 Fold 81.39%(+1.68%p)이나 9~10 평균 60.18%, Batch 10 Acetaldehyde Recall 14 → 4.5%. hard_equal 74.05%(−5.66%p), HGB 66.10%(−13.61%p) | 집중 가스 악화·성능 하락으로 모델 교체 근거 부족 |
| **정답 기반 적응** | 대상 Batch 6·7·8의 평가 50% 고정 후 5·10·20% 정답을 학습에 추가 | Macro F1 80.24% → 92.26% / 93.94% / 94.61%. 5%에서 Toluene 평균 Recall 0.5991 → 0.9448 | 새 시기 정답의 효과가 가장 큼. 같은 Batch 내부 적응이며 정답 확보 필요 → 4.3 재학습 관리로 연결 |

※ 과거 Fold는 Train 1~3→6, 1~6→7, 1~7→8의 Macro F1 동일 가중 평균이며 기준 SVM은 79.71%임. 학습 구간이 겹치므로 독립 반복 실험으로 해석하지 않음. 실험별 세부 수치는 부록 B.

※ signed_log는 부호를 유지한 로그 변환, Yeo-Johnson은 치우친 분포를 정규분포에 가깝게 바꾸는 변환, hard_equal은 시기별로 학습한 SVM들의 예측을 같은 비중의 다수결로 결합하는 방식, HistGradientBoosting은 결정트리를 순차적으로 보완하는 부스팅 모델임.

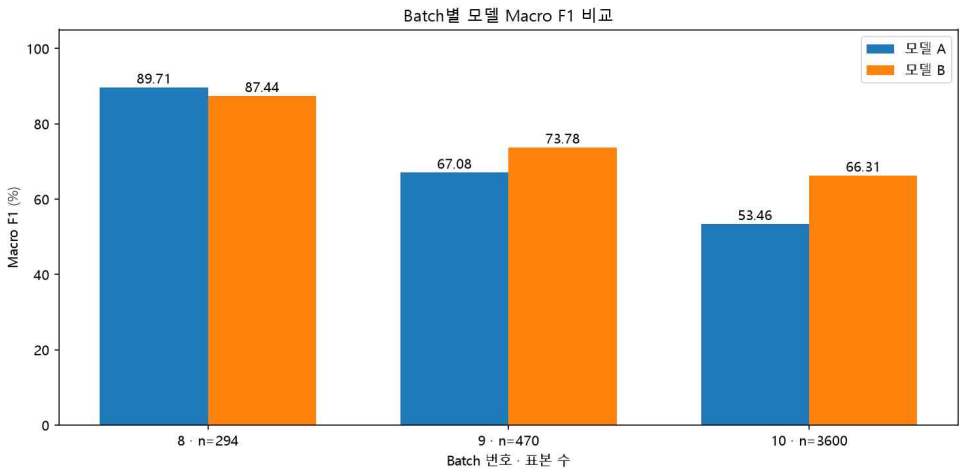



그림 12 SVM 모델(Model A)와 확장 Model B의 Batch별 Macro F1

**표 16 학습 범위 확장에 따른 사후 평가 비교**

| 항목 | SVM 모델(Model A) | 확장 Model B |
|---|---|---|
| 학습 범위 | Batch 1~6 (5,933건) | Batch 1~7 (9,546건) |
| 9~10 합산 Accuracy | 0.5703 | 0.6749 |
| 9~10 합산 Macro F1 | 0.5587 | 0.6775 |
| 9~10 Batch 평균 Macro F1 | 0.6027 | 0.7005 |

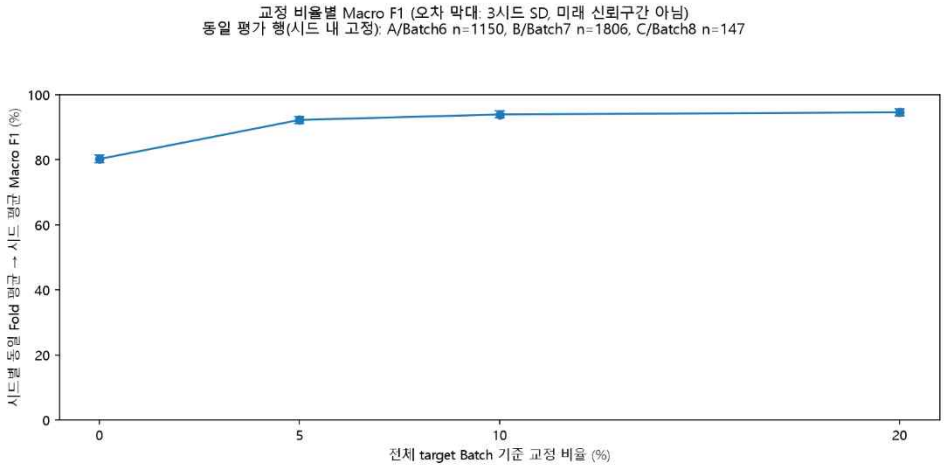



그림 13 대상 Batch의 정답 추가 비율별 Macro F1

○ 학습 범위 확장과 정답 적응은 평균 성능을 크게 높였으나, 전자는 Batch 9 Toluene 실패와 독립 검증 부재, 후자는 같은 Batch 내부의 적응이라는 한계가 남음. 모델·특징 변경보다 학습 데이터의 시기 대표성과 새 시기 정답의 영향이 크다는 판단 근거로 활용함.

※ 0% 기준도 같은 평가 행에서 계산한 별도 값임. 정답 적응은 이후 시기의 독립 성능이나 물리적 센서 교정 효과가 아님.

## 3.5 특징 영향 및 중요도 분석

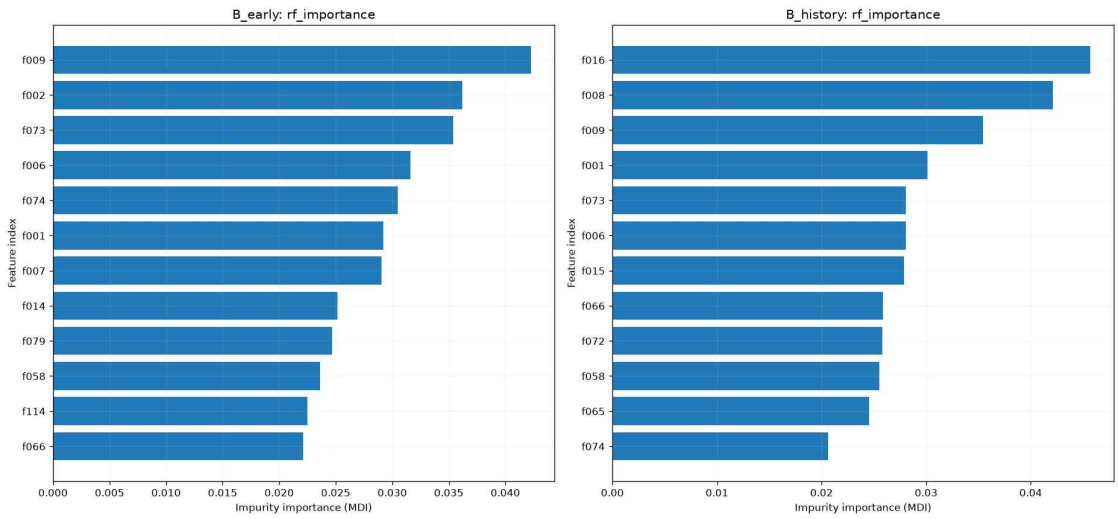



그림 14 초기 Random Forest의 불순도 기반 특징 중요도

**표 17 특징 영향 분석 결과와 모델 성능에 미친 영향**

| 분석 | 주요 결과 | 모델·해석에 미친 영향 |
|---|---|---|
| **Random Forest 중요도** | B_early는 f009·f002·f073, B_history는 f016·f008·f009가 상위. 학습 시기 구성에 따라 순위 변화 | 해당 RF 분할의 상대 기여도이며 공식 SVM의 중요도나 인과 영향이 아님 |
| **저분산 특징 제거** | 128개 → 115개, 과거 Fold 평균 Macro F1 0.797082 → 0.800790(+0.37%p). 상관 제거·KBest 등 다른 선택법은 SVM 평균 하락 | 일관된 개선이 없어 공식 모델은 128개 특징 유지 |
| **SVM 커널 유사도** | 초기 B_history SVM(Train 1~3)에서 Batch 10 정분류 중앙값 0.8931, 오분류 중앙값 0.9599 | 지원벡터와 가깝다는 사실이 올바른 분류를 보장하지 않음. SVM 모델(Model A) 지표가 아님 |

## 3.6 데이터 분포 변화 감지

### 3.6.1 RFF-MMD² 감지 방식

○ 실제 가스 정답이 없는 측정 데이터에서는 Accuracy·Recall을 직접 계산할 수 없음. 기준 데이터와 다른 측정 패턴을 감지하여 기준 가스 재측정과 모델 재검증의 계기를 제공함.

○ 작동 방식: Batch 1~6을 기준 데이터로 삼고, 새로 들어온 데이터를 100행씩 묶어 기준과의 분포 차이 점수를 계산함. 기준 데이터 내부에서도 생기는 자연스러운 점수 범위를 Calibration 자료로 미리 확인하고, 그 95% 수준을 넘으면 '기준과 다른 측정 패턴'으로 경고함. 정답이 없어도 계산할 수 있으나, 경고가 곧 분류 오류나 센서 고장을 뜻하지는 않음.

**표 18 고정 RFF-MMD² 감지기의 입력·기준·판정 구성**

| 항목 | 구성 내용 |
|---|---|
| **입력 및 비교 단위** | f001~f128, 입력 순서대로 100행씩 묶어 기준과 비교 |
| **기준 자료** | Batch 1~6을 Reference 2,966건 / Calibration 1,483건 / 내부 평가 1,484건으로 분리 |
| **전처리·점수** | Reference에서 중앙값 대치·표준화·커널 폭 계산 → RFF 512차원 변환 → 기준과 입력 창 평균 벡터의 제곱 거리 |
| **판정 기준** | Calibration 14개 창 점수의 95백분위수로 임계값 0.00825701197565701 고정, 초과 시 경고 |

※ 정답은 감지기 적합·임계값 결정에 사용하지 않음. 점수를 확률이나 예상 오류율로 해석하지 않음.

### 3.6.2 분포 변화 감지 결과

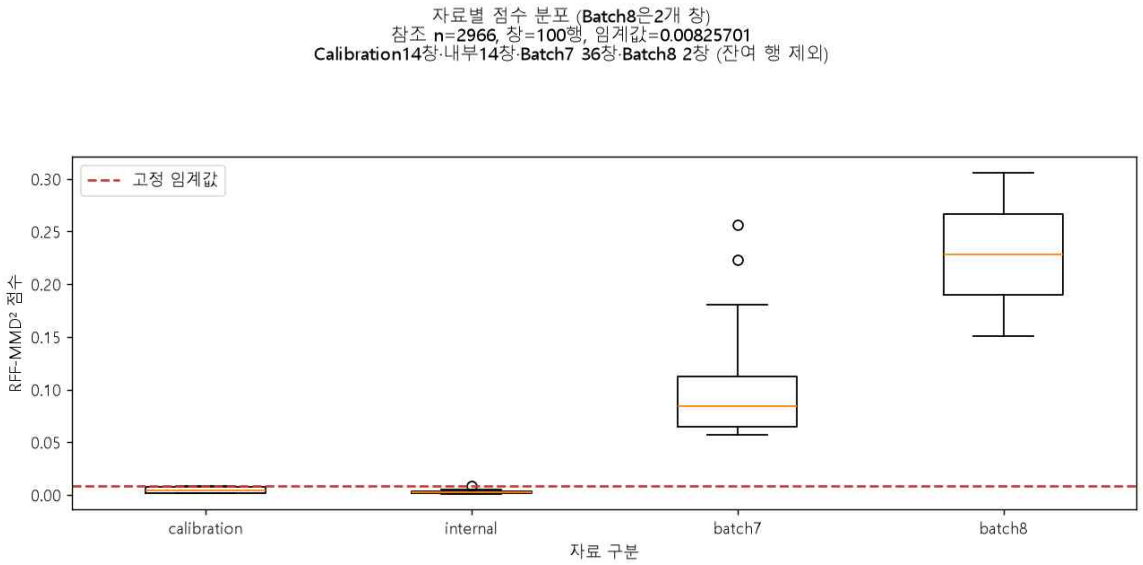



그림 15 기준 내부와 Batch 7~8의 RFF-MMD² 점수

**표 19 고정 임계값 기준 구간별 분포 변화 감지 결과**

| 구간 | 창 수 | 경고 창 | 평균 점수 | 경고율 | 잔여 제외 |
|---|---|---|---|---|---|
| 내부 평가 | 14 | 1 | 0.003143 | 7.14% | 84건 |
| Batch 7 | 36 | 36 | 0.100152 | 100.00% | 13건 |
| Batch 8 | 2 | 2 | 0.228156 | 100.00% | 94건 |

○ Batch 7의 36창과 Batch 8의 2창, 합계 38창 모두 경고되어 내부 평가(14창 중 1창)와 구분되는 분포 차이 확인.

○ 경고된 3,800건 중 오분류는 391건(10.29%)이며, Batch 8의 한 창은 점수 0.305474이나 100건 모두 정분류됨. 점수와 오류율의 Spearman 약 −0.292로, 점수가 높을수록 오류가 많다는 근거 부족.

### 3.6.3 감지기 민감도 및 한계

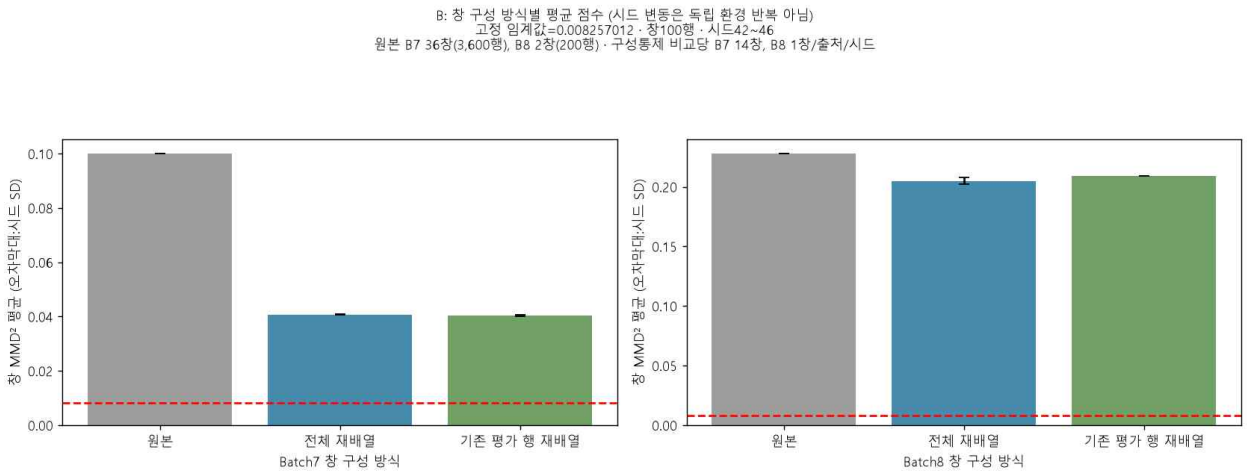



그림 16 창 구성 방식에 따른 평균 MMD² 점수

**표 20 창 구성 방식별 평균 점수와 경고율**

| 창 구성 방식 | Batch 7 평균 점수 | Batch 8 평균 점수 | 대상 경고율 |
|---|---|---|---|
| 원본 파일 순서 | 0.100152 | 0.228156 | 100% |
| 전체 재배열 | 0.040685 | 0.204938 | 100% |
| 평가 행 고정 재배열 | 0.040398 | 0.209090 | 100% |
| 가스 구성 통제 | 0.028181 | 0.222819 | 100% |

○ Batch 7 점수는 재배열 시 약 60%, 가스 구성 통제 시 약 72% 감소하나 대상 경고율 100% 유지. 점수 크기는 입력 가스 구성과 100행 창 묶음 방식에 민감함.

**표 21 분류 오류·통계적 분포 차이·물리적 드리프트 구분**

| 구분 | 확인 가능한 내용 | 판정 범위 |
|---|---|---|
| **가스 분류 오류** | 정답과 predict 비교 | 실제 정답이 있는 경우에만 성능 계산 |
| **통계적 분포 차이** | 기준과 신규 128개 특징의 분포 비교 | 정답 없이 측정 패턴 차이 감지 |
| **물리적 센서 드리프트** | 같은 가스·농도·환경의 통제 반복 측정 | 현재 메타데이터만으로 확정 불가 |

※ $MMD^2$ 점수만으로 실제 센서 고장이나 분류 오류를 확정할 수 없음. 경고·비경고 비교 집합이 없어 감지기의 민감도·특이도는 산출하지 않음. 파일 행 순서는 실제 측정 시간 순서가 아님.

## 3.7 연구 결과 종합

○ 시간순 평가 기준으로 SVM 모델(Model A)를 선정하고, 이후 시기의 성능 저하와 Toluene·Acetaldehyde 집중 실패를 확인함.

○ 개선 실험에서는 모델·특징 변경보다 학습 데이터의 시기 대표성과 새 시기 정답이 성능에 큰 영향을 줌. 공식 모델 교체 대신 정답 없는 상황의 분포 변화 감지와 정답 확보 후 재학습 관리 절차로 연결함(4장).

# 4. 프로토타이핑(화면)

## 4.1 웹앱 개요

○ 센서 연구원과 장비 관리자가 코드를 직접 실행하지 않고 CSV 업로드부터 가스 분류, 측정 패턴 변화, 정답 기반 성능 확인까지 수행하는 로컬 연구용 Streamlit 웹앱 구현.

**표 22 웹앱 사용 흐름**

| 순서 | 사용자 행동 | 실제 구현 기능 |
|---|---|---|
| 1 | 센서 CSV 업로드 | f001~f128 필수, gas 선택. 20MB·20,000행 한도 |
| 2 | 데이터 검증 | 필수 열·자료형·무한대·전체 결측 확인 및 열 순서 재정렬 |
| 3 | 분석 실행 | 운영 모델의 6종 가스 예측과 100행 단위 분포 변화 감지 |
| 4 | 분석 결과 확인 | 예측 분포·패턴 변화·정답 평가·Confusion Matrix·상세 표 |
| 5 | 결과 보관 | 분석 결과 CSV 3종 다운로드 및 분석 당시 모델 버전 기록 |
| 6 | 모델 관리 | 20-A 정답 등록 → 20-B 후보 학습·비교 → 20-C 수동 승인·전환·롤백 |

※ 인증 없는 로컬 프로토타입이며 누출 여부·가스 농도·유해성 판정 기능이 아님.

## 4.2 주요 분석 기능

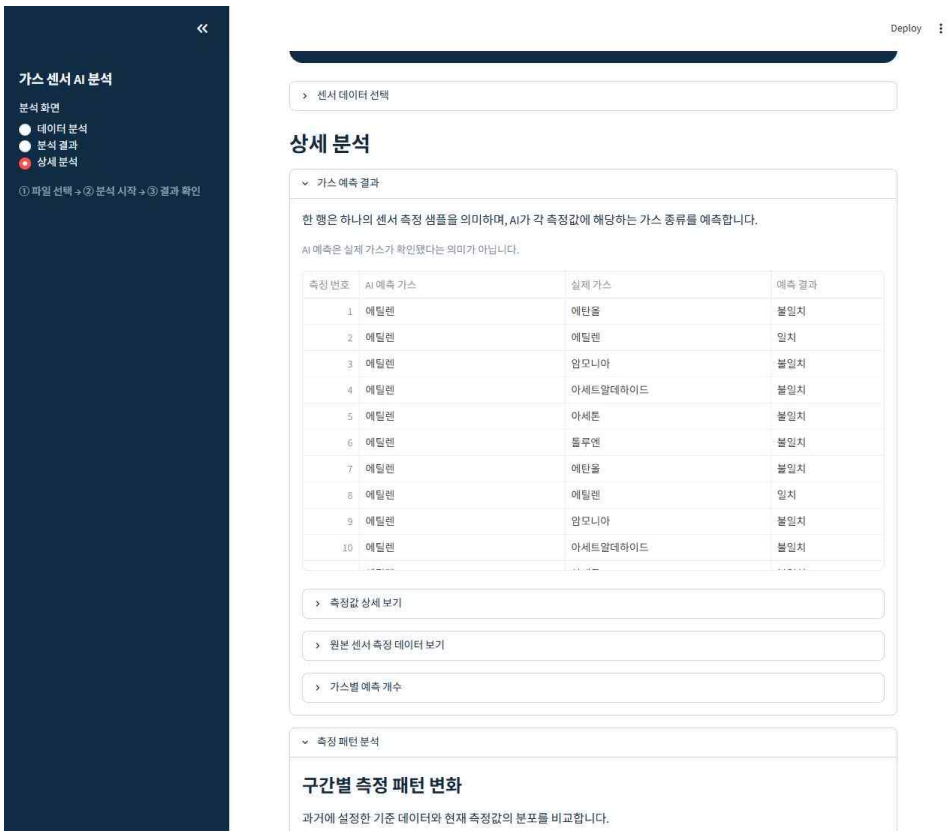



그림 17 상세 분석 — 측정별 예측·정답 비교 화면

○ **가스 분류 결과**: 측정 번호별 AI 예측 가스·실제 가스·일치 여부를 먼저 표시하고, 128개 원본 특징은 접힌 영역에서 확인함.

○ **성능 평가·다운로드**: gas 정답이 있으면 Accuracy·Macro F1·가스별 지표·Confusion Matrix를 제공하고, 정답이 없으면 예측과 분포 감지만 제공함. 분석 결과 CSV 3종 다운로드 구현.




그림 18 구간별 측정 패턴 차이 분석 화면

○ **분포 변화 감지**: 100행 구간별 측정 범위·패턴 차이 점수·고정 기준 초과 여부를 표시하고, 100행을 채우지 못한 구간은 평가 불가로 구분함. 화면에는 '기준과 다른 측정 패턴'으로 안내하며 고장 확정·드리프트 확률로 표시하지 않음.

## 4.3 모델 재학습 및 관리

○ 3.4의 결과처럼 새 시기의 확인된 정답이 성능 회복에 가장 효과적이므로, 정답 데이터 등록부터 후보 학습·비교, 수동 승인·롤백까지의 관리 기능을 구현함. 경고만으로 자동 재학습·교체하지 않음.

※ 20-A·20-B·20-C는 개발 단계 번호이며 각각 정답 데이터 등록·검증, 후보 모델 재학습·성능 비교, 운영 모델 승인·전환·롤백 단계를 의미함.

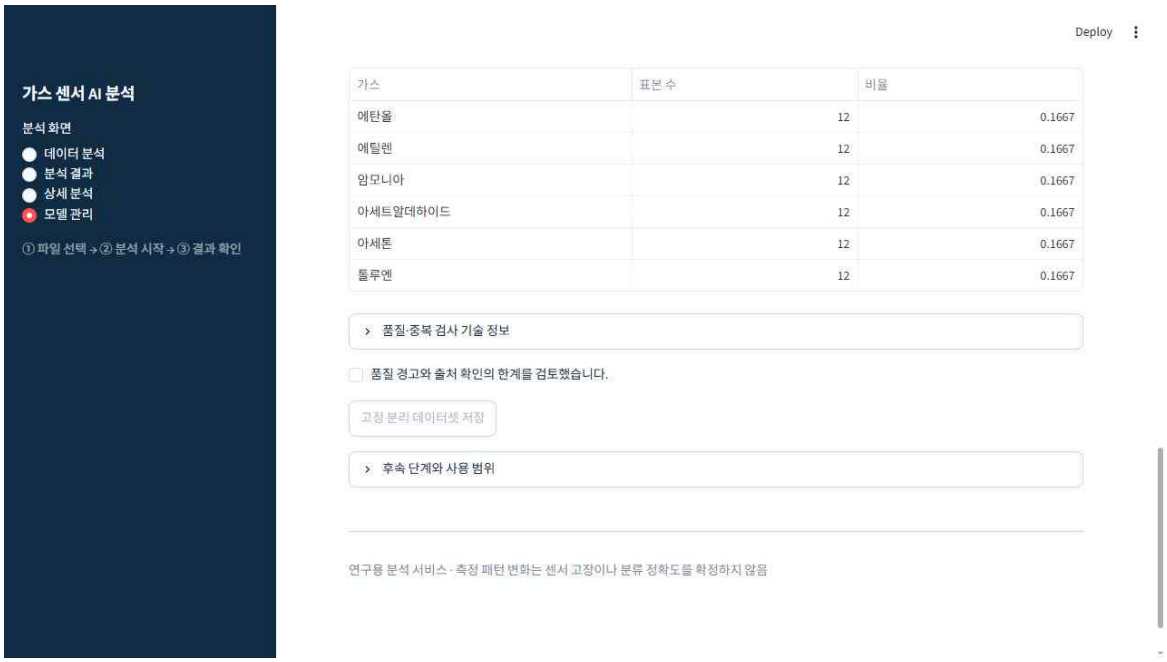



그림 19 20-A 조건 미충족 시 데이터 저장 차단 화면

**표 23 재학습 관리 단계별 핵심 기능과 운영 제한**

| 단계 | 핵심 기능 | 운영상 제한 |
|---|---|---|
| **20-A 정답 데이터 등록·검증** | 확인된 실제 정답·출처·세션 등록, 중복·기존 5,933건과의 중복·과거 Validation 재사용 차단, 최신 세션 Validation / 이전 세션 Train 고정 저장 | 예측값을 정답으로 사용하지 않음. 출처·정답 확인은 사용자 자기신고 기록 |
| **20-B 후보 재학습·성능 비교** | 기존 5,933건 + 신규 Train으로 공식 SVM 설정의 후보 학습(전처리는 Train만), 같은 신규 Validation에서 Accuracy·Macro F1·가스별 지표·Confusion Matrix·OvR ROC/AUC 비교 | 결과는 검토 전용이며 자동 승인·교체 없음 |
| **20-C 승인·전환·롤백** | 같은 Validation 재비교 후 Macro F1 비하락 확인, 수동 승인, 운영 모델 포인터 전환, 버전 이력 기록, 이전 모델 롤백, 실패 시 기존 모델 유지 | 합성 후보 적용 차단. 관리자 로그인·인증 미구현 |

**표 24 20-B 합성 데이터 기능 검증 결과(실제 센서 성능 아님)**

| 기능 검증 지표 | 기존 SVM 모델(Model A) | 합성 후보 | 비고 |
|---|---|---|---|
| Accuracy / Macro F1 | 16.67% / 4.76% | 100% / 100% | 공식 모델은 60행 모두 Ethanol로 예측 |
| 가스별 Recall | Ethanol 100%, 나머지 5종 0% | 6종 모두 100% | 가스별 Validation 10행 |
| 가스별 보조 OvR AUC | 모두 0.5 | 모두 1.0 | 결정점수 순위 평가 |

○ 실제 신규 센서 정답 데이터가 없어, 쉽게 구분되도록 만든 합성 Train 60행·Validation 60행으로 학습·비교·저장 연결만 확인함. 합성 후보의 100%를 실제 성능 개선으로 해석하지 않음.

○ 모델 교체·롤백은 실제 운영과 분리된 임시 테스트 환경에서 검증하였고, 실제 운영 모델은 SVM 모델(Model A)를 유지함. 20-B·20-C 화면 캡처는 본 문서에 미수록.

# 5. 결론 및 향후 과제

## 5.1 결론

○ **공식 모델 선정**: LR·RF·SVM을 랜덤·시간순으로 비교하고, Validation Batch 7~8의 Macro F1 0.8970을 기준으로 balanced RBF SVM을 공식 기준 모델(SVM 모델, Model A)로 선정함.

○ **시간순 성능 저하 확인**: 사후 평가 Batch 9~10에서 Macro F1 0.5587(합산)로 저하되고, Batch 9 Toluene 0/101·Batch 10 Acetaldehyde Recall 14.0%의 집중 실패 확인. OvR Macro AUC는 0.8505임.

○ **주요 개선 실험**: 학습 범위 확장(9~10 Batch 평균 0.7005)과 정답 적응(Macro F1 최대 94.61%)이 효과적이었으나, 독립 검증 부재와 일부 가스 악화로 공식 모델은 유지함.

○ **분포 변화 감지**: 정답 없이 기준과 다른 측정 패턴을 알리는 RFF-MMD² 감지기를 구축하고, 가스 구성·창 구성 민감도와 물리적 해석의 한계를 정리함.

○ **웹앱 및 모델 관리**: Streamlit 업로드·분류·분포 감지·정답 평가·다운로드와 20-A~20-C의 정답 검증·후보 학습·수동 승인·전환·롤백 기능을 구현함. 분석 Notebook의 역할을 나눈 뒤 하나의 Python 웹앱으로 통합 완료(개발 21~22단계).

※ 합성·임시 환경의 기능 검증과 실제 신규 센서 데이터의 성능 개선을 구분함. 후자는 미검증이며 실제 운영 모델은 Model A와 원본 감지기·임계값을 유지함.

## 5.2 주요 트러블슈팅

### 5.2.1 랜덤 분할과 시간순 평가의 성능 차이

| | |
|---|---|
| **문제 상황** | 랜덤 분할 Test Macro F1은 0.98~0.99였으나 시간순 평가는 0.29~0.58로 급락함. 랜덤 최고 모델(RF)이 시간순 공통 Batch 6~10에서는 최저(0.4148)였음. |
| **원인 분석** | 랜덤 분할은 같은 Batch의 다른 표본이 Train에 포함되어 같은 시기 조건을 미리 학습함. 시간순 평가는 학습하지 않은 시기의 분포를 마주함. |
| **해결 또는 개선 시도** | 주 평가를 시간순(Train 1~6 / Validation 7~8 / 사후 평가 9~10)으로 전환하고, Validation만으로 후보를 고정하는 사전 선정 규칙 적용. |
| **검증 결과** | SVM 모델(Model A) 선정(Validation 0.8970). 다만 사후 평가 9~10 Macro F1은 0.6027(Batch 평균)로 낮고 독립 최종 Test는 없음. |

### 5.2.2 Toluene·Acetaldehyde의 심각한 오분류

| | |
|---|---|
| **문제 상황** | Batch 9 Toluene 101건 전부 Ethanol로 오분류(Recall 0%), Batch 10 Acetaldehyde Recall 14%. 평균 지표에서는 실패가 드러나지 않음. |
| **원인 분석** | Train 1~6의 Toluene 85.53%가 Batch 6에 집중되고 Batch 3~5에는 Toluene이 없음. Batch 9 Toluene은 다른 가스의 Train 표본에 더 가깝게 위치함. |
| **해결 또는 개선 시도** | 가스별 Recall·오분류 방향을 분리 진단한 뒤 학습 범위·특징·알고리즘·정답 적응 실험을 같은 보호 기준으로 비교함. |
| **검증 결과** | 범위 확장 Model B에서도 Batch 9 Toluene은 1/101에 그침. 5% 정답 적응에서 Toluene 평균 Recall 0.9448로 회복되어 정답 기반 재학습 관리(20-A~20-C)로 연결함. |

## 5.3 한계점 및 향후 과제

○ **실제 신규 센서 데이터 기반 검증**: 20-A~20-C는 합성 데이터와 임시 환경에서만 검증되었고 독립 최종 Test도 없음. 새 시기의 확인된 정답 데이터로 재학습 절차를 실제 적용하고, 개발에 쓰지 않은 자료에서 한 번만 평가할 필요가 있음.

○ **통계적 분포 변화와 물리적 드리프트의 차이**: 측정 시각·농도·환경·장비 정보가 없어 분포 경고를 센서 상태와 연결할 수 없음. 기준 가스와 조건을 통제한 반복 측정으로 오경보·미탐지를 검증해야 함.

○ **산업 현장 적용·운영 검증**: 128개 특징 정의가 같은 센서인지 호환성 확인, 측정 조건 기록, 인증·접근 통제가 필요함. 현재 모델은 농도·유해성·누출 판단에 사용하지 않음.

### 5.3.1 실제 신규 센서 데이터 기반 독립 검증 설계

본 연구의 사후 성능 평가는 기존 Batch를 활용한 분석 결과임. 실제 적용 가능성을 확인하려면 개발 과정에서 사용하지 않은 신규 측정 자료를 별도 확보하고, 데이터 수집부터 평가까지의 기준을 사전에 고정할 필요가 있음.

**표 25 실제 신규 센서 데이터 기반 독립 검증 설계**

| 검증 항목 | 고정 기준 | 확인 목적 |
|---|---|---|
| **측정 조건** | 장비 ID, 측정 시각, 농도, 온습도, 세션 정보를 함께 기록 | 통계적 분포 변화와 측정 환경 변화를 분리하여 해석 |
| **평가 자료** | 개발에 사용하지 않은 이후 시점의 정답 확보 자료로 구성 | 사후 평가 성능과 독립 검증 성능을 구분 |
| **모델 지표** | Macro F1, 가스별 Recall, 주요 혼동 방향을 함께 평가 | 평균 지표에 가려지는 특정 가스 실패를 확인 |
| **감지기 지표** | 고정 기준 데이터, 100행 윈도우, 임계값을 유지 | 경보율과 실제 측정 조건의 관계를 검증 |

### 5.3.2 운영 적용 전 판단 기준

후보 모델의 일부 지표가 개선되더라도 운영 모델을 즉시 교체하지 않음. 동일한 신규 Validation에서 현재 Model A와 후보 모델을 비교하고, 가스별 Recall 하락 여부와 분포 변화 경보의 해석 가능성을 함께 확인한 뒤 수동 승인 절차를 거쳐 적용 여부를 판단함.

합성 데이터에서 확인한 업로드·재학습·전환·롤백 기능은 구현 범위의 검증 결과임. 실제 신규 센서 데이터에서의 성능 개선 또는 물리적 드리프트 개선으로 확대 해석하지 않으며, 독립 자료 검증 결과를 확보한 뒤 운영 효과를 판단함.

## 5.4 프로젝트 회고

처음에는 랜덤 분할에서 Macro F1이 0.98 이상 나와 모델이 거의 완성됐다고 생각했음. 그런데 과거 Batch로 학습하고 이후 Batch로 평가하자 0.29~0.58까지 떨어졌고, 이때부터 점수를 올리기 전에 '어떤 데이터로, 어떤 순서로 평가했는가'를 먼저 확인하게 됨. 같은 0.9라도 어떻게 나눠서 평가했느냐에 따라 의미가 완전히 달랐고, 이걸 알고 나서야 점수를 믿고 쓸 수 있었음.

성능을 끌어올리려고 모델 종류와 설정을 여러 번 바꿔 봤지만, 결과를 가장 크게 바꾼 것은 학습 데이터에 어느 시기의 측정값이 들어 있느냐였음. 그래서 모델을 더 다듬기보다, 측정 패턴이 기준과 달라졌는지 먼저 알려 주고 정답이 쌓이면 다시 학습하는 흐름을 웹앱에 넣게 됨. 아직은 합성 데이터로 기능이 동작하는 것까지만 봤고, 실제 센서 데이터를 받으면 정말 도움이 되는지 확인해 보고 싶음.

# 부록

## 부록 A 주요 모델 학습 조건

**표 A-1 기준선과 시간순 확장 단계의 학습 조건**

| 항목 | 초기 기준선(2단계) | 시간순 확장 탐색(6단계) |
|---|---|---|
| **학습 범위** | 랜덤 60/20/20, Train 1 / 1~3 시간순 | Batch 1~3 대 Batch 1~6, Validation 7~8 |
| **Logistic Regression** | C=1.0, solver=lbfgs | C=0.1 또는 10, balanced·Robust 대조 |
| **Random Forest** | 100 trees, depth 제한 없음 | trees=200 또는 depth=12·leaf=3 |
| **SVM (RBF)** | C=1.0, gamma=scale | C=10 또는 gamma=0.001, balanced 비교 |
| **공통** | random_state=42, 이 단계 탐색 없음 | 총 17회 학습, Validation만으로 선정 |

## 부록 B 단계별 개선 실험 비교

**표 B-1 단계별 실험 결과와 판정 범위**

| 단계 | 확인된 수행·관찰 | 판정 범위 |
|---|---|---|
| 초기~5 | EDA·고정 기준선·가스별 실패 진단 및 개선 후보 비교 | 기존 Test 재사용; 미래 안정성 미확인 |
| 6~10 | 시간순 학습 확장·가중치·저장 A/B 검증 | SVM 모델 유지; 새 독립 Test 없음 |
| 11~13 | Toluene 심층 진단·학습 구성 통제·가스별 시기 균형 | 13단계 부분 개선; 전반적 성공 아님 |
| 14 | signed_log 평균 Macro F1 0.800290, 기준 0.797082 | +0.003208; 부분 개선 |
| 15 | 동일 시기 SVM 전문가 결합; hard_equal 평균 F1 74.05% | 기준 대비 −5.66pp; SVM 모델 유지 |
| 16 | HGB 평균 Macro F1 66.10%, SVM 대비 −13.61pp | 개선 근거 부족 |
| 17 | 같은 목표 Batch 내 5/10/20% 정답 활용 적응 | 지도학습 적응; 미래 독립 성능 아님 |
| 18~18.5 | 고정 RFF-MMD² 감지 및 창 재배열 민감도 검토 | 기술적 프로토타입; 물리적 감지 정확도 미확인 |

※ 단계 번호는 개발 기록상의 진행 순서임.

## 부록 C 정답 기반 적응 세부 결과

부록 C는 3.4의 '정답 기반 적응' 실험(그림 13)의 세부 수치임. 새 시기의 확인된 정답을 조금만 학습에 추가해도 성능이 회복되는지 확인하기 위해, 평가 대상 Batch(6·7·8)의 정답 중 5·10·20%를 학습에 추가하고 나머지로 평가함. 0%는 정답을 추가하지 않은 기준값임.

○ 표 C-1: 추가한 정답 비율별 평균 Macro F1. 5%만 추가해도 0.8024에서 0.9226으로 약 12%p 상승하고, 이후 증가 폭은 작아짐.

○ 표 C-2: 5%를 추가했을 때 가스별 평균 Recall 변화. Toluene이 0.5991에서 0.9448로 가장 크게 회복됨.

○ 같은 시기의 정답을 사용한 결과이므로 이후 시기의 독립 성능을 뜻하지 않음. 정답 데이터를 등록해 재학습하는 4.3의 기능(20-A~20-C)을 만든 근거로 활용함.

**표 C-1 정답 추가 비율별 평균 Macro F1**

| 정답 추가 비율 | 평균 Macro F1 | 기준 대비 변화 pp |
|---|---|---|
| 0% | 0.802428 | +0.0000 |
| 5% | 0.922580 | +12.0152 |
| 10% | 0.939445 | +13.7017 |
| 20% | 0.946083 | +14.3655 |

**표 C-2 정답 5% 추가 전후의 가스별 평균 Recall**

| 가스 | 0% 평균 Recall | 5% 평균 Recall | 변화 %p |
|---|---|---|---|
| Ethanol | 0.9728 | 0.9914 | +1.86 |
| Ethylene | 0.9223 | 0.9223 | +0.00 |
| Ammonia | 0.8158 | 0.8201 | +0.43 |
| Acetaldehyde | 0.8618 | 0.9347 | +7.29 |
| Acetone | 0.9130 | 0.9287 | +1.57 |
| Toluene | 0.5991 | 0.9448 | +34.57 |

※ 0%는 동일한 50% 평가 행에서 계산한 별도 기준이며, 5/10/20%의 분모는 전체 대상 Batch임. 평균 Recall의 유지·상승이 개별 Fold·시드에서 하락이 없음을 보장하지 않음.

## 참고문헌


[1] Vergara, A. (2012). Gas Sensor Array Drift Dataset [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5RP6W

[2] Vergara, A., Vembu, S., Ayhan, T., Ryan, M. A., Homer, M. L., & Huerta, R. (2012). Chemical gas sensor drift compensation using classifier ensembles. Sensors and Actuators B: Chemical, 166–167, 320–329. https://doi.org/10.1016/j.snb.2012.01.074

[3] Gretton, A., Borgwardt, K. M., Rasch, M. J., Schölkopf, B., & Smola, A. (2012). A kernel two-sample test. Journal of Machine Learning Research, 13, 723–773.

[4] Rahimi, A., & Recht, B. (2007). Random features for large-scale kernel machines. Advances in Neural Information Processing Systems 20 (NIPS 2007), 1177–1184.

[5] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

[6] Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. Nature, 585, 357–362. https://doi.org/10.1038/s41586-020-2649-2

[7] McKinney, W. (2010). Data structures for statistical computing in Python. Proceedings of the 9th Python in Science Conference, 56–61.

[8] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90–95.

[9] Streamlit. Streamlit documentation. https://docs.streamlit.io (웹앱 구현에 사용)


※ [1]·[2]는 사용 데이터셋과 원 논문, [3]·[4]는 분포 변화 감지(RFF-MMD²)의 이론적 근거, [5]~[9]는 분석과 웹앱 구현에 사용한 라이브러리임.